

パーソナライズ画像生成


6つのお題から1つ選び、好きな絵を数枚選ぶと、パーソナライズなし・ありの4枚ずつを並べて見比べられます。好みはカードに付けた説明文（Reference Prompt）になり、テキストエンコーダーの中でお題の文（Target Prompt）に混ざります。追加学習はしません。

1 全体の流れ



2 FAN の仕組み

H. Kim, S. Ahn, Y.-D. Seo. Foundation Encoders Are All You Need for Preference-Aware Personalization. CVPR 2026.



(a) **Tailored profiling** Reference Prompt（青）から Target Prompt（赤）に対する代表を選ぶ。
(b) **Personalized attention** Target Prompt のトークンが Reference Prompt にも self-attention を向ける。重みは共有。
(c) **Conditioning optimization** PA と SA の層を組み合わせ、Target Prompt を保って好みを反映。

図: github.com/Burf/FAN の asset/method.png
(© 2026 Hyungjin Kim, MIT License)

FAN は、画像生成モデルに好みを伝えるために、**テキストエンコーダーの self-attention だけを組み替える**手法です。追加の学習も、アダプターのような追加の構造も使いません。展示では SDXL の2つのテキストエンコーダー（CLIP-L と OpenCLIP bigG）の両方に適用しています。

1回のエンコードで起きること

Target Prompt と Reference Prompt を 77 トークンにそろえ、1つのバッチで入れる

Target Prompt

PA で Reference Prompt を混ぜる本体。Query は自身、Key と Value は同じ層の「Target Prompt の複製 || 全 Reference Prompt」から作る。最後にこの出力だけを生成モデルへ渡す。

Target Prompt の複製

通常の self-attention のまま進む。α = 0 なら Target Prompt はこれだけを見るので、通常のエンコードと同じ結果になる。

Reference Prompt 1 … R

それぞれ通常の self-attention のまま進む。互いに混ざることはない。

$$H = (1 - \alpha) \cdot \text{Attn}(Q, T) V_T + \alpha \sum_r (w_r / \sum w) \cdot \text{Attn}(Q, R_r) V_{R_r}$$

$\text{Attn}(Q, K) = \text{softmax}(QK^T / \sqrt{d_k})$ 。Q は Target Prompt、T はその複製、 R_r は Reference Prompt r
softmax は文ごとに別々に計算。α は Reference Prompt 全体の割合、w はその中の配分。展示の α = 0.5

0.5

0.25

0.125

0.125

例: α = 0.5、Reference Prompt 3つの weight が 2 / 1 / 1 → Target Prompt 0.5 ・ 各 Reference Prompt 0.25 / 0.125 / 0.125
Reference Prompt の中でどのトークンを見るかは、Query と Key の近さで決まる。

画像に効いている PA の層 CLIP-L: 12層のうち 1〜10 層目（10層）・ OpenCLIP bigG: 32層のうち 1〜30 層目（30層）
0 層目だけ SA のまま（skip_pa）、hidden states は最終層の1つ手前から取る（skip = -2）。

3 Reference Prompt の作り方



例：カード「街角の少女」に付いている句

- 色

warm color palette, amber tones
- 光

overcast, diffused light, soft shadows
- 描画

sketch, visible pencil lines, rough drawing
- 雰囲気

serious, stern expression

被写体語を含めない

句は色・光・描画・雰囲気の表現だけ。

重み = strength × aspect_gain

カードの強さ × 項目（色・光など）ごとの倍率。

同じ句は1件にまとめる

複数のカードで重なったら weight を合算。

「外す」は取り除く

負の重みにはしない。

4 検証で決めた設定

skip_pa	0	0 層目だけ PA なし（公式と同じ）
use_attn_mask	true	Reference Prompt の padding を無視し、好みと無関係な「もや」を防ぐ
alpha	0.5	好みは両方向に効き、被写体も保たれる値
pooled_mode	plain	pooled 埋め込みは Reference Prompt なしの値（公式からの逸脱）

5 生成設定

生成モデル	Illustrious XL v2.0
解像度 / steps	1024 × 1280 / 30
sampler	DPM++ 2M SDE Karras
CFG / 精度	5.0 / fp16
VAE	sdxl-vae-fp16-fix
seed	230923〜230926（固定）



GitHub
tmp-friends/
personalized-t2i



X
@tmp_friends